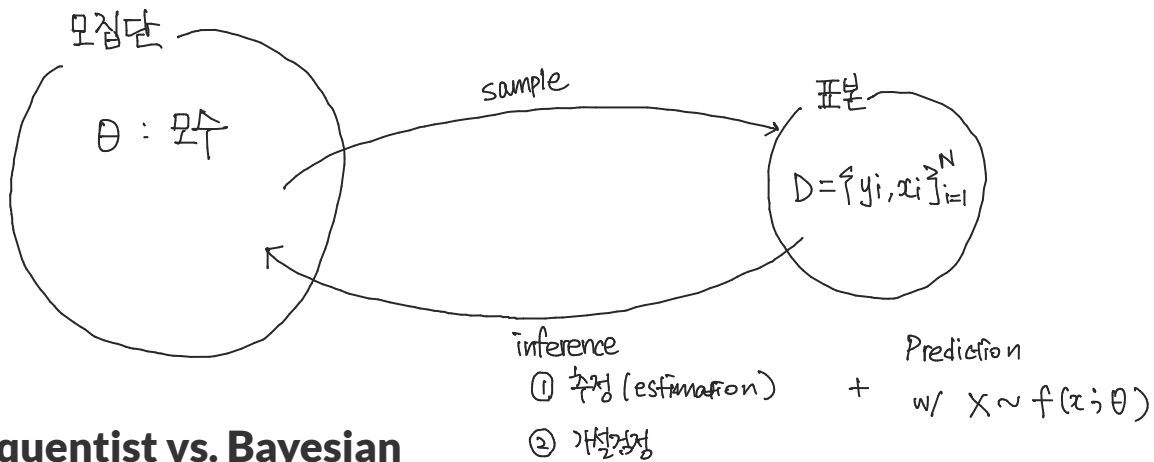


# Bayesian Statistics

## Purpose of Statistics : Inference and Prediction



## Frequentist vs. Bayesian


위와 같은 통계학의 문제들을 해결하는 데 두 가지 접근법이 Frequentist (빈도론적 통계학)와 Bayesian (베이지안 통계학)이다.

## 들어가기 전에 : PDF (probability density function)과 Likelihood Function

$$y_i \sim \underbrace{f(x_i, \theta)}_{\text{known } \theta} \implies \underbrace{L(\theta | x, y)}_{\text{unknown } \theta}$$

density function : 전적으로 모수  $\theta$ 에 의해 결정되는 함수 ( $\theta$ 를 알아야 pdf 아니냐,,)

likelihood : data의 함수



## Frequentist : Fixed Parameter, Random Data

빈도론적 관점에서 추론(Inference)은 알지는 못하지만 고정된 상수로 존재하는 모수  $\theta^*$ 를 찾는 것이다. 그리고 이런 ' $\theta$ 가 뭐냐'라는 물음에 대해서 확률적으로 답한다.

$D = \{y_i, x_i\}$  : data

$$\hat{\theta} = s(D) + \left[ \begin{array}{c} \text{error bound} \\ \text{w.r.t. } \theta \end{array} \right]$$

%

## Estimation : How to answer about error bound?

1. Solve optimization problem (e.g. MLE) :  $\hat{\theta} = s(\mathcal{D}) = \max_{\theta} l(\theta|\mathcal{D})$

2. Error bound : Confidence Interval

- (Asymptotic) Sampling distribution of  $s(\mathcal{D})$  : 극한분포 구하기

- Bootstrapping : 시간과 비용이 넘 비쌘다

$\mathcal{D} \longrightarrow \mathcal{D}_1^*, \mathcal{D}_2^*, \mathcal{D}_3^*, \dots, \mathcal{D}_B^*$

$s(\mathcal{D}_1^*) \quad s(\mathcal{D}_2^*) \quad \dots \quad s(\mathcal{D}_B^*) \Rightarrow \text{empirical dist.}$

## Hypothesis Testing : 너무 이분법적이야!

그리고 여러모로 p-value가 불러오는 오해에 빠지기 쉬움...

**Prediction** : 어떤 "분포"에 대해서 예측

$$\tilde{y}_i \sim f(\tilde{x}_i, \hat{\theta})$$

Uncertainty of the prediction comes from

1. Uncertainty of parameter estimate  $\hat{\theta}$
2. Inherent variability in  $\tilde{y}_i$

## Bayesian : Fixed Data, Random Parameter

$\hat{\theta}$  = a distribution of  $\theta$  given data

빈도론적 관점과의 가장 큰 차이를 모수  $\theta$ 를 random variable로 본다는 것이다! 베이زي안 관점에서 모르는 건 (uncertainty) 다 확률변수라고 생각한다.


## Estimation : full probability model

$$\text{Bayes Rule : } p(\theta|\mathcal{D}) = \frac{p(\mathcal{D}, \theta)}{p(\mathcal{D})} = \frac{p(\mathcal{D}|\theta)p(\theta)}{\int p(\mathcal{D}|\theta)p(\theta)d\theta}$$

$p(\theta)$  : Prior

$p(\mathcal{D}|\theta)$  : Likelihood (observed data per each value of  $\theta$ )

$p(\theta|\mathcal{D})$  : Posterior



Bayesian process is all about applying Bayes Rule!

## Prediction : weighted average over all possible $\theta$

베이지안 관점에서는 모수에 대한 답을 '분포'의 형태로 내린다!

$$\tilde{y}_i \sim p(\tilde{y}_i | \mathcal{D}) = \int \underbrace{p(y_i | \theta)}_{\text{likelihood}} \underbrace{p(\theta | \mathcal{D})}_{\text{posterior}} d\theta \quad \begin{array}{l} \text{w.r.t. } \theta \\ \text{모든 } \theta \text{ 에 대한} \\ \text{weighted avg.} \end{array}$$

## Problems

### 1. Prior on $\theta$

- 모수에 대한 사전적인 믿음/지식이 0이라면 어떻게 하죠...?
- 어떤 scale에 대해서 uniform한 prior를 줄건데...?
- prior를 변수변환에 대해서 invariant하게 줄 수 있어...?

No clear answer...

### 2. Normalizing constant : 보통 적분이 어려움

Solution ? Given that  $p(\theta | \mathcal{D}) \propto p(\theta, \mathcal{D}) \dots$

- Use conjugacy
- MCMC (Markov Chain Monte Carlo) : sample from posterior
- Approximate posterior : normal approx, variational inference... etc.